



A AURORA ESTABELECE OS
PRIMEIROS SISTEMAS DA COLÔNIA

- A REGRESSÃO
INICIAL QUE
PERMITE PREVER
VARIÁVEIS DA
NOVA BASE

7

LISTA DE FIGURAS

Figura 1 – Representação gráfica do tempo médio de respostas em ms	14
Figura 2 – Cálculo do parâmetro β_1	16
Figura 3 – Cálculo do parâmetro β_0	17
Figura 4 – Saída do código e implementação do código de regressão linear	20
Figura 5 – Saída do código de análise de resíduos	22

EMAP

LISTA DE TABELAS

Tabela 1 – Base de dados do tempo médio de respostas de requisições simultâneas	8
Tabela 2 – Desenvolvimento dos cálculos das requisições simultâneas	16

EMENDAS

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 – Implementação do código de regressão linear	19
Código-fonte 2 – Implementação do código de análise de resíduos	21

EMSE

SUMÁRIO

REGRESSÃO LINEAR SIMPLES	6
1 INTRODUÇÃO À MODELAGEM LINEAR	6
2 FUNDAMENTOS DA REGRESSÃO LINEAR	7
2.1 A relação entre variáveis	7
2.2 O modelo aditivo	9
2.3 Como encontrar os coeficientes	11
2.3.1 O método dos mínimos quadrados: Ideia Intuitiva	11
2.3.2 Exemplo do método dos mínimos quadrados	13
2.4 Implementação computacional	18
2.5 Interpretação e avaliação do modelo	20
2.5.1 Coeficiente de determinação (R^2)	20
2.5.2 Análise dos resíduos	21
2.6 Erros e generalização	22
2.7 Aplicações práticas	23
2.8 Limitações e extensões	24
REFERÊNCIAS	25

REGRESSÃO LINEAR SIMPLES

1 INTRODUÇÃO À MODELAGEM LINEAR

A modelagem linear é o primeiro passo para compreender o funcionamento dos modelos preditivos em ciência de dados e aprendizado de máquina. Por meio dela, é possível descrever matematicamente a relação entre variáveis, aproximando fenômenos reais com uma estrutura simples e interpretável.

“Os modelos de regressão são largamente utilizados em diversas áreas do conhecimento, tais como: computação, administração, engenharias, biologia, agronomia, saúde, sociologia etc.” (Guimarães, 2011, p. 1). Essa versatilidade se deve ao fato de que muitos fenômenos apresentam comportamento linear aproximado dentro de determinado intervalo.

A regressão linear é uma ferramenta essencial para compreender e prever relações entre variáveis que se influenciam mutuamente em sistemas reais. Por meio dela, é possível traduzir observações empíricas em um modelo matemático que explica como uma variável se comporta em função de outra, tornando o comportamento de um sistema previsível e mensurável.

O ponto de partida da modelagem está na formulação de perguntas simples, porém fundamentais, que buscam compreender como diferentes variáveis se relacionam em sistemas reais. Antes de qualquer equação, o processo começa com a seguinte observação: será que uma mudança em determinado fator provoca, de forma consistente, uma variação em outro?

Essas perguntas aparecem em diversos contextos da ciência de dados e da computação, como:

- O tempo de resposta de um servidor aumenta à medida que cresce o número de usuários conectados simultaneamente?
- O número de cliques em um anúncio digital tem impacto direto sobre o volume de vendas de um produto em uma campanha online?
- O consumo de energia de um *datacenter* se eleva proporcionalmente à quantidade de requisições processadas por segundo?

Essas situações ilustram o tipo de problema que a regressão linear busca representar matematicamente: as relações de dependência entre variáveis, nas quais identificar a tendência e a intensidade da variação permite prever comportamentos, otimizar recursos e apoiar decisões baseadas em dados. É a partir dessas questões iniciais que o raciocínio se transforma em um modelo capaz de quantificar relações e antecipar resultados, unindo observação empírica, interpretação analítica e aplicação computacional.

Essas situações, comuns em projetos de diferentes áreas, envolvem fenômenos que, dentro de certos limites, apresentam comportamento linear, ou seja, mudanças em uma variável tendem a produzir variações proporcionais em outra. O papel da regressão linear é justamente quantificar essa relação. Ao ajustar uma reta que melhor representa os dados observados, o modelo permite estimar valores futuros, identificar tendências e compreender a intensidade do impacto que uma variável exerce sobre a outra.

Em outras palavras, ela transforma perguntas operacionais em respostas numéricas e preditivas, fundamentais para o processo de tomada de decisão e para o desenvolvimento de sistemas inteligentes.

2 FUNDAMENTOS DA REGRESSÃO LINEAR

2.1 A relação entre variáveis

Em um problema de regressão linear, o objetivo central é encontrar uma relação matemática que descreva o comportamento de uma variável de interesse (Y) em função de uma variável explicativa (X). Em outras palavras, busca-se compreender como alterações em X impactam, de forma previsível, os valores de Y .

Essa relação pode ser expressa pela equação da reta $Y = \beta_0 + \beta_1 X + \varepsilon$. Alguns livros e artigos apresentam essa mesma equação como $Y = \alpha + \beta X + \varepsilon$, mas a diferença apenas está na notação adotada. Aqui, vamos usar o primeiro modelo.

Analisando: Y representa a variável dependente, ou seja, a resposta que queremos obter. X é a variável independente, ou a explicativa. β_0 representa o

intercepto, o valor de Y quando $X = 0$. β_1 é o coeficiente angular (a inclinação da reta). ε , por fim, representa o erro aleatório, ou seja, os fatores não observados.

A regressão linear procura identificar a reta que melhor traduz o comportamento médio dos dados, minimizando as discrepâncias entre os valores observados e os valores estimados pelo modelo. Ao fazer isso, permite compreender a direção e a intensidade da relação entre as variáveis, além de estimar resultados futuros com base em padrões históricos.

Para compreender de forma prática como a equação da regressão linear é construída, observe o conjunto de dados a seguir, que relaciona o número de requisições simultâneas (X) em um servidor e o tempo médio de resposta (Y) em milissegundos (ms).

Requisições simultâneas (X)	Tempo médio de resposta (Y) em ms
5	105
10	118
15	132
20	145
25	160
30	172

Tabela 1 – Base de dados do tempo médio de respostas de requisições simultâneas
Fonte: Elaborada pela autora (2025)

Visualmente, o gráfico de dispersão desses pontos apresenta uma tendência crescente e quase linear, indicando que, conforme aumenta o número de requisições, o tempo médio de resposta também cresce de forma previsível.

A equação de regressão desse modelo é $\hat{y} = 95,83x + 2,53x$. Isso significa que, quando $X = 0$, o tempo médio esperado seria aproximadamente 95,83 ms, o que representa a latência base do sistema, isto é, o tempo mínimo necessário para processar uma requisição mesmo sem carga. Também podemos entender que, a cada requisição, o tempo médio de resposta aumenta 2,53 ms, em média.

Essa equação, embora simples em sua forma, constitui o alicerce conceitual de grande parte dos algoritmos de aprendizado supervisionado. Em termos práticos, esse modelo atua como uma ponte entre a análise descritiva e a predição computacional, transformando dados dispersos em conhecimento mensurável, um passo essencial para o desenvolvimento de sistemas inteligentes e de suporte à decisão.

A linearidade da regressão está nos parâmetros α e β , ou β_0 e β_1 ; já as variáveis não precisam necessariamente ser lineares. Em modelos mais complexos,

o método ainda é considerado linear quando os parâmetros β_0 e β_1 aparecerem de forma não multiplicada entre si, mesmo tendo equações com logaritmos, polinomiais ou exponenciais.

A linearidade em um modelo de regressão refere-se aos parâmetros estimados, e não, necessariamente, às variáveis explicativas. O termo linear é utilizado porque o modelo é linear nos parâmetros da regressão, e não porque a variável dependente Y seja obrigatoriamente uma função linear de X , conforme Bussab e Morettin (2015) explicam. Isso significa que a natureza linear está na forma como os coeficientes β_0 e β_1 aparecem na equação, sem multiplicações ou potências entre si, e não no comportamento direto das variáveis.

Mesmo em modelos mais sofisticados, que utilizam transformações logarítmicas, termos polinomiais ou funções exponenciais, o método ainda é considerado linear: os parâmetros devem permanecer em estrutura linear. Essa característica garante ao modelo flexibilidade para representar diferentes padrões de dados, preservando ao mesmo tempo a simplicidade matemática e a facilidade de interpretação que tornam a regressão linear tão amplamente utilizada.

O algoritmo de regressão linear é treinado com um conjunto de dados conhecido, que chamamos de base de treinamento. Com esses valores de treino, ele ajusta os valores de β_0 e β_1 de modo a minimizar a diferença entre os valores reais, os valores que foram observados e os valores previstos que representamos por $\hat{y}$. O resultado é um modelo capaz de generalizar o comportamento dos dados e realizar previsões para novos cenários, mesmo que não tenham sido observados anteriormente. Sob a ótica computacional, esse modelo constitui o ponto de partida para o aprendizado supervisionado.

2.2 O modelo aditivo

A regressão linear simples faz parte de uma família mais ampla de modelos conhecidos como aditivos, nos quais o valor observado de uma variável resposta é formado pela soma de um componente sistemático, que representa o efeito das variáveis explicativas, e de um componente aleatório, que expressa as variações não explicadas pelo modelo.

De forma geral, o modelo aditivo é representado pela seguinte equação:

$$Y = \psi(X) + \varepsilon$$

Nessa função, $\psi(X)$ representa o comportamento determinístico da variável resposta, ou seja, descreve a parte que pode ser explicada matematicamente. Por outro lado, ε representa o termo de erro aleatório, que contém ruídos, as flutuações e fatores externos não observados.

De acordo com Marques e Lopes (2017), esse modelo traduz a ideia de que o mundo real é composto por padrões regulares e variações imprevisíveis. O papel do modelo linear é capturar o primeiro grupo, a regularidade, e reconhecer o segundo, a aleatoriedade.

Em uma perspectiva aplicada à ciência de dados, o componente $\psi(X)$ é o que o algoritmo tenta aprender durante o treinamento: ele resume o padrão geral existente entre as variáveis, de modo que o modelo possa realizar previsões coerentes mesmo diante de novos dados. Já o termo ε irá indicar a presença de incertezas e ruídos inevitáveis nos sistemas computacionais e experimentais.

Quando se assume que $\psi(X)$ é uma função linear, o modelo aditivo torna-se o modelo de regressão linear simples, que abordamos anteriormente.

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Essa formulação destaca a separação conceitual entre o padrão e o acaso, algo fundamental na modelagem estatística. Enquanto a parte linear da função, representada por $\beta_0 + \beta_1 X$, fornece uma estimativa média e previsível de Y , o termo ε assegura que o modelo reconheça que há sempre um grau de incerteza e que duas observações com o mesmo valor de X podem produzir valores ligeiramente diferentes de Y , devido a variáveis não controladas.

Segundo Maia (2017), essa distinção é o que torna o modelo linear uma ferramenta poderosa, já que os melhores estimadores lineares são encontrados sob condições de linearidade, homoscedasticidade e independência. Isso significa que, dentro dessas condições, os coeficientes estimados β_0 e β_1 possuem baixa variabilidade, ausência de viés e alta precisão estatística.

Em termos práticos, compreender o modelo aditivo ajuda a entender que nenhum modelo prevê o futuro com exatidão. Toda predição contém uma margem de erro, mas o papel do cientista de dados e do engenheiro de software é reduzir ao

máximo essa incerteza, buscando representar matematicamente o comportamento predominante do sistema. É dessa forma que a modelagem linear se torna uma ponte entre o comportamento esperado dos dados e a imprevisibilidade natural dos fenômenos reais.

2.3 Como encontrar os coeficientes

Em um modelo de regressão linear, compreender a forma da equação é apenas o primeiro passo. O verdadeiro desafio está em descobrir os valores dos coeficientes, β_0 e β_1 , que fazem com que a reta ajustada represente com precisão o comportamento real dos dados observados. Em outras palavras, buscamos a reta que melhor se aproxima dos pontos experimentais, ou seja, aquela que descreve de maneira fiel a tendência entre as variáveis analisadas.

Esse processo é o coração da modelagem linear: transformar dados dispersos em uma relação previsível, encontrando os parâmetros que minimizam a diferença entre os valores observados (Y) e os valores estimados pelo modelo ($\hat{Y}$). Para isso, utiliza-se um método matemático conhecido como método dos mínimos quadrados.

2.3.1 O método dos mínimos quadrados: Ideia Intuitiva

Para encontrar os coeficientes da equação de regressão, é preciso determinar a reta que melhor se ajusta aos dados observados. Mas o que significa, na prática, “melhor ajuste”? De maneira intuitiva, é aquela reta que passa o mais próximo possível dos pontos reais, minimizando a diferença entre os valores observados (Y) e os valores previstos pelo modelo ($\hat{Y}$).

Cada uma dessas diferenças é chamada de erro ou resíduo, e é representada por:

$$e_i = y_i - \hat{y}_i$$

Como os resíduos podem ser positivos ou negativos, a simples soma deles poderia resultar em zero, mascarando os erros individuais. Por isso, o método utiliza o quadrado dos resíduos, garantindo que todos os desvios sejam positivos e que os maiores erros tenham mais peso no cálculo.

A soma de todos esses quadrados é conhecida como Soma dos Quadrados dos Erros (SQE) ou Soma dos Quadrados dos Resíduos (SSE). Ela é expressa por:

$$S(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

O método dos mínimos quadrados ordinários (MMQ) consiste em encontrar os valores de β_0 e β_1 que tornam essa soma o menor possível, isto é, a reta que minimiza o erro total de predição.

Após a aplicação das derivadas parciais e simplificações matemáticas (que serão apresentadas de forma prática nos cálculos a seguir), obtêm-se as fórmulas gerais dos coeficientes:

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

A reta de regressão estimada é expressa como:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Essas expressões mostram que a inclinação da reta ($\hat{\beta}_1$) depende da covariância entre X e Y (como as duas variam juntas) e da variância de X (quanto X se afasta de sua média). Já o intercepto ($\hat{\beta}_0$) é o valor de Y quando X é zero, ajustado pela média dos dados.

Em termos práticos, o processo pode ser resumido em três etapas:

1. Calcular as médias ($\bar{x}$ e $\bar{y}$) das variáveis observadas;
2. Determinar os desvios em relação às médias ($x_i - \bar{x}$ e $y_i - \bar{y}$) e seus produtos;
3. Aplicar as fórmulas dos coeficientes para obter a equação da reta que melhor representa a relação entre X e Y .

A seguir será apresentado um exemplo numérico detalhado, mostrando o passo a passo de como esses cálculos são realizados a partir de uma pequena base de dados, evidenciando como a teoria se transforma em prática.

2.3.2 Exemplo do método dos mínimos quadrados

Considere uma empresa de tecnologia voltada à hospedagem de aplicações e serviços de API, interessada em analisar o comportamento do tempo médio de resposta de seus servidores em função do número de requisições simultâneas. O estudo dessa relação permite avaliar o desempenho da infraestrutura e identificar padrões de crescimento que orientem decisões de escalabilidade.

O objetivo da equipe de engenharia de software é prever como o sistema reage conforme a carga de usuários aumenta, para planejar melhorias de infraestrutura, como balanceadores de carga, instâncias adicionais em nuvem e mecanismos de cache. Essas medidas são fundamentais para manter a qualidade do serviço e cumprir os acordos de nível de serviço firmados com os clientes.

Durante uma bateria de testes controlados, os engenheiros coletaram dados de desempenho de um dos servidores. Em cada rodada, aumentou-se gradualmente o número de requisições simultâneas X , e o tempo médio de resposta Y foi medido em milissegundos. Os resultados obtidos estão na tabela “Base de dados do tempo médio de respostas de requisições simultâneas”.

Ao representar esses valores em um gráfico de dispersão, disposto na figura “Representação gráfica do tempo médio de respostas em ms”, observa-se um padrão de crescimento quase linear. Conforme o número de requisições aumenta, o tempo médio de resposta cresce de maneira quase proporcional, o que sugere que o servidor ainda está operando dentro de uma faixa estável, sem sobrecarga crítica.




Figura 1 – Representação gráfica do tempo médio de respostas em ms
Fonte: Elaborada pela autora (2025)

Visualmente, a tendência indica que o comportamento do sistema pode ser bem aproximado por uma reta, pelo menos até certo ponto antes da saturação de recursos, como CPU, memória e rede.

Para compreender de forma concreta como o método dos mínimos quadrados é aplicado, vamos detalhar passo a passo os cálculos realizados a partir dos dados da tabela “Base de dados do tempo médio de respostas de requisições simultâneas”. O primeiro passo é calcular a média de X e a média de Y . A média aritmética é uma medida de tendência central: somamos todos os valores observados e dividimos pelo número de observações.

$$\bar{x} = \frac{5 + 10 + 15 + 20 + 25 + 30}{6} = 17,5$$

No caso das requisições simultâneas, somamos todos os valores de X e dividimos por 6 (porque temos seis testes). O resultado é a média das requisições, indicada por $\bar{x} = 17,5$.

Da mesma forma, somamos todos os tempos médios de resposta e dividimos por 6, obtendo a média dos tempos, indicada por $\bar{y} = 138,7$.

$$\bar{y} = \frac{105 + 118 + 132 + 145 + 160 + 172}{6} = 138,7$$

Intuitivamente, $\bar{x}$ e $\bar{y}$ representam o centro dos dados em cada variável. Em regressão linear simples, esse ponto médio $(\bar{x}, \bar{y})$ é tão importante que a reta ajustada sempre passa por ele: é como se a média fosse o ponto de equilíbrio do conjunto de observações.

Para construir a reta de regressão, é necessário organizar os cálculos em uma tabela que mostre, para cada observação, as diferenças e os produtos usados nas fórmulas dos coeficientes.

Cada coluna da tabela possui uma função específica no cálculo dos coeficientes da regressão e ajuda a compreender como o modelo é construído a partir dos dados observados:

- x_i : representa os valores observados da variável independente; neste caso, o número de requisições simultâneas. Cada linha da tabela corresponde a uma medição feita durante o experimento;
- y_i : são os valores observados da variável dependente, isto é, o tempo médio de resposta do servidor, medido em milissegundos para cada nível de carga;
- $x_i - \bar{x}$: indica o desvio de cada valor de X em relação à média. Mostra o quanto cada observação se afasta do valor médio das requisições ($\bar{x}$). Valores negativos indicam observações abaixo da média; valores positivos, acima dela;
- $(x_i - \bar{x})^2$: corresponde ao quadrado do desvio de X. Esses valores são sempre positivos e servem para medir a variabilidade da variável X. Quanto maiores forem esses valores, maior é a dispersão das observações em torno da média;
- $y_i - \bar{y}$: representa o desvio de cada valor de Y em relação à média. Mostra se o tempo de resposta de uma observação está acima ou abaixo do tempo médio geral ($\bar{y}$);
- $(x_i - \bar{x})(y_i - \bar{y})$: é o produto dos desvios de X e Y. Esse valor é fundamental, pois indica como as duas variáveis variam juntas: se aumentam e diminuem ao mesmo tempo (relação positiva) ou em sentidos opostos (relação negativa).

Em resumo, cada linha da tabela mostra o comportamento de um par de observações (x_i, y_i) , enquanto as colunas intermediárias revelam como os dados se distribuem em torno das médias e como X e Y se relacionam entre si. Essas informações são o alicerce do método dos mínimos quadrados: a partir delas, é possível encontrar a inclinação e o intercepto da reta que melhor representa o comportamento dos dados.

A última linha da tabela apresenta o somatório dos valores de cada coluna, representado pelo símbolo Σ (sigma), que indica “soma de todos os elementos”. Esses somatórios são essenciais para a aplicação das fórmulas do método dos mínimos

quadrados, pois a partir deles são obtidos os valores necessários para calcular os coeficientes da reta de regressão.

Na sequência, a tabela apresenta todos os valores já resolvidos, evidenciando a aplicação prática do método dos mínimos quadrados e a forma como cada termo contribui para a obtenção dos coeficientes da regressão.

x_i	y_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$
5	105	-12,5	156,25	-33,7	421,25
10	118	-7,5	56,25	-20,7	155,25
15	132	-2,5	6,25	-6,7	16,75
20	145	2,5	6,25	6,3	15,75
25	160	7,5	56,25	21,3	159,75
30	172	12,5	156,25	33,3	416,25
$\sum$			437,5		1184,0

Tabela 2 – Desenvolvimento dos cálculos das requisições simultâneas
Fonte: Elaborada pela autora (2025)

Para determinar o valor do parâmetro $\hat{\beta}_1$, basta substituir na fórmula dos estimadores os respectivos somatórios encontrados.

A seguir, estão apresentados os valores calculados para cada etapa, com base nas médias obtidas anteriormente. Ao realizar essa substituição, é possível visualizar o cálculo completo e o resultado final do coeficiente angular, conforme apresentado na figura a seguir.

$$\hat{\beta}_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$$

$$\hat{\beta}_1 = \frac{1184}{437,5} = 2,70$$

Figura 2 – Cálculo do parâmetro $\hat{\beta}_1$
Fonte: Elaborada pela autora (2025)

O parâmetro $\hat{\beta}_0$, que representa o intercepto da reta de regressão, é obtido pela substituição direta dos valores estimados na expressão correspondente, como apresentado na figura abaixo.

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$
$$\hat{\beta}_0 = 138,7 - 2,70(17,5)$$
$$\hat{\beta}_0 = 91,4$$

Figura 3 – Cálculo do parâmetro $\hat{\beta}_0$
Fonte: Elaborada pela autora (2025)

Esse valor representa o intercepto da reta, ou seja, o ponto em que a linha de regressão cruza o eixo Y. No contexto do problema, ele corresponde ao tempo médio de resposta do servidor quando não há requisições simultâneas, refletindo a latência mínima do sistema, isto é, o tempo necessário apenas para processar uma solicitação isolada.

A equipe, então, ajusta um modelo de regressão linear simples para representar a relação entre o número de requisições simultâneas e o tempo médio de resposta.

O modelo estimado, obtido pelo método dos mínimos quadrados, é dado por:

$$\hat{Y} = 91,4 + 2,70X$$

Em que:

- $\beta_0 = 91,4$ representa o tempo base de resposta, a latência mínima do servidor, quando não há requisições simultâneas;
- $\beta_1 = 2,70$ indica que a cada nova requisição simultânea, o tempo médio de resposta aumenta em 2,7 ms, em média.

Essa equação funciona como uma ferramenta preditiva para o time técnico, permitindo estimar o desempenho do sistema sob diferentes níveis de carga. Por exemplo, se o servidor estiver processando 40 requisições simultâneas, o tempo médio de resposta previsto pode ser calculado substituindo o valor de $X = 40$ na equação $\hat{Y} = 91,4 + 2,70(40) = 199,4$ ms. Isso significa que, com 40 requisições simultâneas, o servidor tende a responder, em média, em aproximadamente 199 milissegundos.

Essas estimativas permitem antecipar limites operacionais e detectar o ponto em que o sistema começará a ultrapassar o tempo máximo de resposta. Com base nisso, a equipe pode definir políticas automáticas de escalonamento horizontal, ativando novos servidores sempre que o modelo prever que o tempo médio de resposta se aproximará de um limiar crítico.

Do ponto de vista de aprendizado de máquina, esse exemplo mostra como a regressão linear pode modelar relações quantitativas entre variáveis de desempenho, fornecendo:

- Uma visão quantitativa do comportamento do sistema sob diferentes cargas;
- Uma forma de prever resultados futuros a partir de dados históricos;
- Uma base para decisões automatizadas, como o aumento dinâmico de recursos de nuvem.

Esse tipo de modelagem é amplamente utilizado em engenharia de software, infraestrutura de TI e ciência de dados aplicada à otimização de desempenho, demonstrando que a regressão linear não é apenas uma ferramenta estatística de análise, mas também um instrumento de controle e previsão em sistemas computacionais em tempo real.

2.4 Implementação computacional

Esse método pode ser facilmente implementado em Python, utilizando bibliotecas amplamente empregadas em ciência de dados, como Pandas, NumPy, Matplotlib e Scikit-learn. Essas ferramentas permitem organizar os dados, ajustar o modelo, visualizar o resultado e avaliar o desempenho da regressão de forma prática e intuitiva. O código a seguir apresenta a implementação completa do modelo proposto no exemplo anterior.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

# Dados simulados
dados = {'requisições': [5, 10, 15, 20, 25, 30],
        'tempo_ms': [105, 118, 132, 145, 160, 172]}
```

```
df = pd.DataFrame(dados)

# Separação das variáveis
X = df[['requisições']]
y = df['tempo_ms']

# Criação e ajuste do modelo
modelo = LinearRegression()
modelo.fit(X, y)

# Parâmetros estimados
print("Intercepto ( $\beta_0$ ):", modelo.intercept_)
print("Inclinação ( $\beta_1$ ):", modelo.coef_[0])

# Predição
y_pred = modelo.predict(X)

# Gráfico
plt.scatter(X, y, color='blue', label='Observado')
plt.plot(X, y_pred, color='red', label='Ajuste Linear')
plt.xlabel('Requisições simultâneas')
plt.ylabel('Tempo médio de resposta (ms)')
plt.legend()
plt.show()
```

Código-fonte 1 – Implementação do código de regressão linear
Fonte: Elaborado pela autora (2025)

O gráfico resultante mostra uma linha de tendência que representa o comportamento médio do sistema. Essa é uma das grandes forças da regressão linear: permitir visualizar e quantificar relações.

Na figura “Saída do código e implementação do código de regressão linear”, é possível visualizar a saída gerada pela execução do código, mostrando os coeficientes da regressão e o desempenho do modelo aplicado aos dados.




Figura 4 – Saída do código e implementação do código de regressão linear
Fonte: Elaborada pela autora (2025)

Esses resultados confirmam a tendência identificada anteriormente e demonstram, na prática, como a regressão linear pode ser implementada para analisar e prever o comportamento de sistemas reais.

2.5 Interpretação e avaliação do modelo

2.5.1 Coeficiente de determinação (R^2)

O coeficiente de determinação, representado por R^2 , indica quanto da variação observada na variável dependente (Y) é explicada pela variável independente (X) por meio do modelo de regressão. Em outras palavras, ele mede o grau de ajuste do modelo aos dados: quanto mais próximo de 1 for o valor de R^2 , melhor o modelo representa a realidade observada.

Matematicamente, o coeficiente é expresso por:

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

O termo $\sum (y_i - \hat{y}_i)^2$ representa a soma dos quadrados dos resíduos, ou seja, as diferenças entre os valores observados e os valores previstos pelo modelo. Já $\sum (y_i - \bar{y})^2$ expressa a soma total dos quadrados, que mede a variabilidade total dos dados em torno da média.

No exemplo do servidor, um valor elevado de R^2 indica que grande parte da variação no tempo médio de resposta é explicada pelo número de requisições simultâneas, evidenciando um bom ajuste do modelo.

Em resumo, o coeficiente R^2 funciona como uma medida de qualidade da regressão, já que valores próximos de 1 sugerem que o modelo explica bem o comportamento dos dados, enquanto valores mais baixos indicam que há outros fatores, além de X, influenciando Y.

2.5.2 Análise dos resíduos

Os resíduos, representados por $e_i = y_i - \hat{y}_i$, correspondem à diferença entre o valor observado e o valor previsto pelo modelo. Eles indicam o erro de previsão cometido pela regressão em cada observação e, portanto, são fundamentais para avaliar a qualidade e a validade do ajuste.

Em um modelo bem ajustado, espera-se que os resíduos se distribuam aleatoriamente em torno de zero, sem formar padrões visíveis. Essa aleatoriedade indica que o modelo capturou adequadamente a tendência dos dados e que os erros são resultado apenas de variações naturais e imprevisíveis.

A análise dos resíduos, portanto, é uma etapa essencial da modelagem, pois permite verificar a adequação do modelo, identificar possíveis inconsistências e melhorar a precisão das previsões.

Para verificar visualmente o comportamento dos resíduos, é possível construir um gráfico de dispersão entre os valores previstos ($\hat{Y}$) e os resíduos (e_i), uma ferramenta simples e eficaz para avaliar se há padrões sistemáticos ou pontos discrepantes (*outliers*) que indiquem falhas no modelo.

Abaixo segue um exemplo de código que plota a análise de resíduos.

```
residuos = y - y_pred
plt.scatter(y_pred, residuos)
plt.axhline(y=0, color='red', linestyle='--')
plt.xlabel('Valores preditos')
plt.ylabel('Resíduos')
plt.title('Análise dos Resíduos')
plt.show()
```

Código-fonte 2 – Implementação do código de análise de resíduos

Fonte: Elaborado pela autora (2025)

Na figura a seguir podemos observar a saída gerada por esse código.




Figura 5 – Saída do código de análise de resíduos
Fonte: Elaborada pela autora (2025)

Se os pontos estiverem distribuídos de forma aleatória em torno da linha vermelha (que representa o eixo zero), isso indica que o modelo linear é adequado e que os erros são essencialmente aleatórios. Por outro lado, padrões visuais, como uma forma de parábola, agrupamentos ou concentração em apenas uma região, podem sugerir que o modelo não capturou corretamente a relação entre as variáveis, sendo necessário incluir novas ou testar uma forma funcional diferente, como um modelo polinomial.

2.6 Erros e generalização

De acordo com Izbicki e Mendonça (2017), o objetivo de um modelo preditivo é minimizar o erro de predição esperado, ou seja, reduzir ao máximo a diferença entre os valores previstos pelo modelo e os valores reais observados.

O erro pode ser decomposto em três partes:

$$E[(Y - \hat{\psi}(X))^2] = \text{Viés}^2 + \text{Variância} + \sigma^2$$

- Viés: diferença entre o valor esperado da predição e o valor real;
- Variância: quanto o modelo muda quando os dados mudam;
- Erro irreduzível (σ^2): ruído intrínseco do sistema, impossível de eliminar.

O equilíbrio entre viés e variância é conhecido como **trade-off viés–variância**. Modelos muito simples costumam apresentar alto viés e baixa variância, caracterizando o subajuste (*underfitting*), enquanto modelos muito complexos tendem a ter baixo viés e alta variância, resultando em sobreajuste (*overfitting*).

A capacidade de um modelo de encontrar esse ponto de equilíbrio é o que determina sua habilidade de generalizar bem, ou seja, de produzir boas previsões em dados novos, diferentes daqueles usados no treinamento.

2.7 Aplicações práticas

A regressão linear é uma das técnicas mais utilizadas em projetos reais de ciência de dados e computação, pois permite identificar relações entre variáveis e realizar previsões de forma simples, eficiente e interpretável. Seu uso é recorrente em diferentes contextos tecnológicos e empresariais, como:

1. Previsão de tempo de resposta em sistemas web, permitindo estimar o desempenho de servidores conforme a carga de requisições aumenta;
2. Estimativa de consumo energético de processadores, a partir da relação entre carga de trabalho e uso de energia;
3. Análise de custo por demanda em serviços de *cloud computing*, auxiliando na precificação e na otimização de recursos;
4. Previsão de vendas em campanhas digitais, relacionando investimentos em mídia e resultados comerciais.

Esses exemplos mostram como a regressão linear pode ser aplicada tanto em problemas de infraestrutura tecnológica quanto em decisões estratégicas baseadas em dados.

Um caso clássico é o conjunto de dados *Advertising* (Marques; Lopes, 2017), em que os gastos com publicidade em TV, rádio e jornal são usados para explicar o volume de vendas de um produto. A análise revela que os investimentos em TV e rádio exercem forte influência positiva sobre as vendas, enquanto o gasto em jornais apresenta impacto pouco significativo. Essa é uma informação valiosa para otimizar o investimento em marketing e maximizar o retorno financeiro.

Em resumo, a regressão linear se destaca por unir simplicidade matemática, interpretação direta e ampla aplicabilidade, tornando-se uma ferramenta essencial para profissionais que desejam compreender padrões e antecipar comportamentos em ambientes orientados por dados.

2.8 Limitações e extensões

A regressão linear simples, embora poderosa e amplamente utilizada, possui suas limitações.

Quando o fenômeno estudado envolve múltiplos fatores que influenciam o resultado, o modelo deve ser expandido para incluir mais de uma variável explicativa, originando a regressão linear múltipla. Além disso, há situações em que a relação entre as variáveis não é estritamente linear.

Nesses casos, é possível aplicar transformações matemáticas, como logaritmos, raízes ou exponenciais, ou adotar modelos polinomiais, que preservam o raciocínio linear, mas aumentam a flexibilidade do modelo, permitindo representar padrões de comportamento mais complexos.

Essas variações mantêm a simplicidade e a interpretação do modelo linear, ao mesmo tempo em que ampliam sua capacidade de adaptação e representação de fenômenos reais.

REFERÊNCIAS

BUSSAB, Wilton de Oliveira; MORETTIN, Pedro Alberto. **Estatística Básica**. 8. ed. São Paulo: Saraiva, 2015.

DUBINSKI, Juliana; JOMAR, Paulo. **Regressão Linear Simples – Exercício Experimental**. [S.l.]: [s.n.], s.d.

GONZALEZ, Manoel. **Estatística Aplicada à Engenharia e à Computação**. 3. ed. São Paulo: Pearson, 2018.

GUIMARÃES, Paulo Roberto Barbosa. **Análise de Regressão**. Curitiba: Universidade Federal do Paraná, 2011.

IZBICKI, Rafael; MENDONÇA, Tiago. **Machine Learning sob a ótica estatística: uma abordagem preditivista para a estatística com exemplos em R**. São Carlos: UFSCar/Insper, 2017.

MAIA, Alexandre Gori. **Econometria: conceitos e aplicações**. Campinas: Editora Unicamp, 2017.

MARQUES, Paulo C.; LOPES, Hedibert F. **Fundamentos de Aprendizagem Estatística: Regressão**. São Paulo: FGV, 2017.

MONTGOMERY, Douglas C.; RUNGER, George C. **Estatística Aplicada e Probabilidade para Engenheiros**. 6. ed. Rio de Janeiro: LTC, 2016.

VALLE, Flávio da Cunha; REIS, Elizabeth dos; MIGON, Helio S. **Introdução à Inferência Bayesiana**. 2. ed. Rio de Janeiro: SBM, 2020.