

ENERGIA PARA SOBREVIVER

A REGRESSÃO
LOGÍSTICA QUE
CLASSIFICA
CENÁRIOS PARA
DECISÕES
ENERGÉTICAS

6

LISTA DE FIGURAS

Figura 1 – Função logística	10
Figura 2 – Print do resultado código-fonte 2.....	16
Figura 3 – Representação da fronteira de decisão.....	17
Figura 4 – Métricas fundamentais do modelo.....	21
Figura 5 – Matriz de confusão do modelo	21
Figura 6 – Impressão do código-fonte 4.....	25
Figura 7 – Impressão do código-fonte 5.....	26
Figura 8 – Impressão do código-fonte 6.....	28
Figura 9 – Impressão do código-fonte para 643 dados.....	29

LISTA DE TABELAS

Tabela 1 – Tentativas de acesso simuladas	23
---	----

EMBR

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 – Estrutura básica de uso da regressão logística no <i>scikit-learn</i>	14
Código-fonte 2 – Modelo de regressão logística aplicado a dados artificiais	15
Código-fonte 3 – Exemplo de código-fonte HTML.....	20
Código-fonte 4 – Regressão logística com três variáveis e 20 observações	25
Código-fonte 5 – Código para encontrar os coeficientes.....	26
Código-fonte 6 – Código da fronteira de decisão com variável fixa.....	27

EMANIP

SUMÁRIO

REGRESSÃO LOGÍSTICA.....	6
1 FUNDAMENTOS ESTATÍSTICOS, INTERPRETAÇÃO E IMPLEMENTAÇÃO COMPUTACIONAL	6
1.1 Motivação: Quando a regressão linear deixa de ser suficiente	6
1.2 Diferença entre regressão e classificação: Por que a regressão logística é necessária?	6
2 FUNDAMENTOS MATEMÁTICOS DA REGRESSÃO LOGÍSTICA.....	8
2.1 Probabilidade, chances e <i>log-odds</i>	8
2.2 Interpretação probabilística	10
2.3 A função de custo: Entropia cruzada.....	11
2.4 Otimização via gradiente descendente	12
3 IMPLEMENTAÇÃO COMPUTACIONAL	13
3.1 Estrutura geral no <i>scikit-learn</i>	13
3.2 Exemplo com dados sintéticos	14
3.3 Fronteira de decisão.....	16
3.4 Interpretação dos coeficientes.....	18
4 AVALIAÇÃO DO MODELO	19
4.1 Métricas fundamentais	19
4.2 Curva ROC e AUC	19
4.3 Validação cruzada.....	20
4.4 Exemplo	20
5 APLICAÇÕES E CONEXÕES DA REGRESSÃO LOGÍSTICA	22
5.1 Exemplo de detecção de acesso suspeito	23
6 CONCLUSÃO.....	30
REFERÊNCIAS.....	31
GLOSSÁRIO	32

REGRESSÃO LOGÍSTICA

1 FUNDAMENTOS ESTATÍSTICOS, INTERPRETAÇÃO E IMPLEMENTAÇÃO COMPUTACIONAL

1.1 Motivação: Quando a regressão linear deixa de ser suficiente

Grande parte dos problemas corporativos, industriais e computacionais envolve prever um resultado binário: aprovar ou recusar um crédito, converter ou não um cliente, identificar ou não um comportamento anômalo, detectar ou não uma falha. Esse tipo de problema caracteriza o que chamamos de classificação binária, em que a variável resposta assume apenas dois estados possíveis: 0 ou 1.

Modelos de classificação desse tipo exigem que o sistema forneça uma probabilidade bem definida para a ocorrência do evento, conforme discutido por Simeone (2018) e Izbicki & Santos (2020).

A regressão linear não é adequada para esse cenário: suas previsões são não limitadas, podendo assumir valores negativos ou superiores a 1, e sua função de perda quadrática não captura corretamente os custos associados aos erros de classificação.

Nesse contexto, a regressão logística desempenha um papel fundamental. Ela é um modelo especificamente desenvolvido para problemas de classificação binária, convertendo uma combinação linear das variáveis explicativas em uma probabilidade no intervalo de 0 a 1. Como parte da família dos modelos lineares generalizados, conforme apresentado por Bishop (2006), a regressão logística utiliza a função logística para realizar esse mapeamento probabilístico, permitindo interpretar diretamente a saída do modelo como a probabilidade do evento de interesse ocorrer.

1.2 Diferença entre regressão e classificação: Por que a regressão logística é necessária?

A distinção entre regressão e classificação é fundamental para compreender o papel da regressão logística nos modelos preditivos. Embora ambos os problemas

façam parte do aprendizado supervisionado, eles respondem a perguntas diferentes e lidam com estruturas estatísticas distintas.

Na regressão, o objetivo é prever um valor numérico contínuo, como temperatura, faturamento, tempo de execução ou número de acessos. O modelo busca estimar a média condicional de uma variável quantitativa. A regressão linear, nesse caso, é apropriada: sua saída é um número real sem restrição de intervalo e sua função de perda quadrática é adequada para medir erros contínuos.

Já na classificação, o objetivo não é prever um número contínuo, mas sim atribuir um rótulo a cada observação. Em particular, na classificação binária, a variável resposta assume apenas dois valores possíveis, frequentemente codificados como 0 e 1. O interesse principal não é a predição direta de um valor, mas sim a probabilidade de ocorrência do evento, como *churn*, fraude, falha ou spam. Essa interpretação probabilística é fundamental em ambientes corporativos e de engenharia, pois decisões estratégicas frequentemente dependem da estimativa de risco.

Os modelos de classificação precisam fornecer uma boa aproximação para a probabilidade condicional $\Pr(Y = 1 | X = x)$, pois é essa estimativa que orienta decisões posteriores, como definição do ponto de corte, priorização de ações, configuração de alertas e avaliação de risco operacional (Simeone, 2018).

A regressão linear, apesar de simples, não atende a esses requisitos. Suas previsões extrapolam o intervalo $[0,1]$, inviabilizando a interpretação probabilística. Além disso, a função de perda quadrática não reflete adequadamente os custos assimétricos típicos da classificação, nos quais errar um positivo pode ter impacto diferente de errar um negativo, conforme discutido por Izbicki & Santos (2020).

A regressão logística resolve esses problemas ao modelar diretamente a probabilidade do evento por meio da função logística. Essa abordagem garante que a saída do modelo esteja sempre entre 0 e 1, permitindo uma interpretação estatística clara. Bishop (2006) explica que esse mapeamento é parte essencial dos modelos lineares generalizados, nos quais a transformação adequada da variável resposta possibilita a utilização de estruturas lineares na predição.

Assim, a regressão logística estabelece a ponte exata entre modelos lineares e problemas de classificação, preservando a interpretabilidade e oferecendo uma

formulação matemática robusta para estimar probabilidades de forma adequada e coerente.

2 FUNDAMENTOS MATEMÁTICOS DA REGRESSÃO LOGÍSTICA

A regressão logística possui uma base estatística fundamentada em conceitos que permitem transformar uma combinação linear de variáveis explicativas em uma probabilidade interpretável. Para compreender plenamente como o modelo opera, é necessário revisar alguns elementos matemáticos essenciais, como probabilidade, chances, *log-odds*, função logística e a estrutura probabilística que define o comportamento da variável resposta. Esses componentes aparecem de maneira consistente e formam o arcabouço teórico que sustenta a interpretação e o processo de ajuste do modelo.

2.1 Probabilidade, chances e *log-odds*

Para compreender a estrutura interna da regressão logística, é importante distinguir três quantidades fundamentais: probabilidade, chances (*odds*) e *log-odds* (*logito*). Esses conceitos têm origem direta na distribuição Bernoulli, que modela variáveis aleatórias com apenas dois resultados possíveis, normalmente representados por 0 e 1. Nessa distribuição, um único parâmetro p determina a probabilidade do evento assumir o valor 1, enquanto o valor complementar representa a probabilidade associada ao valor 0. Como cada observação da variável resposta em um problema de classificação binária pode ser interpretada como uma realização dessa distribuição, a regressão logística trata cada y como um resultado gerado por uma Bernoulli cuja probabilidade depende das características da observação. A partir desse parâmetro p derivam-se as chances, que expressam o quão mais provável é a ocorrência do evento em relação à sua não ocorrência, e o *log-odds*, que corresponde à transformação logarítmica dessa razão. Essa transformação converte a relação entre sucesso e fracasso em uma escala contínua na reta real, permitindo que o *logito* seja modelado como uma combinação linear das variáveis explicativas. Assim, probabilidade, chances e *log-odds* constituem elementos matemáticos diretamente

associados à distribuição Bernoulli e formam o alicerce estatístico que sustenta a formulação da regressão logística.

A probabilidade, definida como $p(x) = \Pr(Y = 1 | X = x)$, indica a probabilidade de que a observação pertença à classe positiva, dadas as suas características $X = x$. Por construção, p varia apenas entre 0 e 1.

As chances, ou *odds*, definidas como $odds = \frac{p}{(1-p)}$ ou ainda $odds(x) = \frac{\Pr(Y = 1 | X = x)}{1 - \Pr(Y = 1 | X = x)}$, representam “quanto mais provável é o evento ocorrer do que não ocorrer”. Quando $p = 0,5$, as chances são iguais a 1; quando p é maior que 0,5, as chances aumentam; e quando p é pequena, as chances se aproximam de zero. Diferentemente da probabilidade, os valores de *odds* variam no intervalo $(0, \infty)$.

Log-odds, também chamado *logito*, é descrito por $\text{logit}(p(x)) = \ln\left(\frac{p(x)}{1-p(x)}\right)$

ou ainda $\ln \frac{\Pr(Y=1|X=x)}{(1-\Pr(Y=1|X=x))}$. Essa transformação logarítmica é essencial porque converte a escala assimétrica das *odds* em uma variável que pode assumir qualquer valor real, de menos infinito a mais infinito. Essa propriedade resolve o principal obstáculo da modelagem: probabilidades são limitadas, mas o *logito* não, permitindo que seja representado por uma combinação linear das variáveis explicativas.

Esse é o ponto central da regressão logística: o modelo assume que o *log-odds* da classe positiva é uma função linear dos preditores, isto é:

$$\text{logit}(p(x)) = b_0 + b_1x_1 + \dots + b_kx_k.$$

Essa formulação estabelece uma ponte entre um espaço linear (a combinação dos preditores) e um espaço probabilístico. Para recuperar a probabilidade propriamente dita, aplica-se a função logística, que inverte o *logito*:

$$p(x) = \frac{1}{1 + \exp [-(b_0 + b_1x_1 + \dots + b_kx_k)]}$$

De forma equivalente:

$$\Pr(Y = 1 | X = x) = \sigma(b_0 + \sum_{j=1}^k b_jx_j)$$

Em que :

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

A sigmoide garante que qualquer valor real produzido pela combinação linear dos parâmetros seja convertido em uma probabilidade válida, pertencente ao intervalo $[0,1]$. O termo “sigmoide” vem do formato da curva, que lembra a letra “S”.




Figura 1 – Função logística
Fonte: Brains (2023)

Essa transformação é o mecanismo fundamental que torna a regressão logística um modelo probabilístico apropriado para classificação binária.

2.2 Interpretação probabilística

A regressão logística é, antes de tudo, um modelo probabilístico. Sua principal função não é apenas classificar observações, mas estimar a probabilidade de que uma instância pertença à classe positiva, dadas suas características. Esse enfoque distingue a regressão logística de modelos puramente determinísticos, pois ela fornece:

- Uma distribuição de probabilidade condicional $Pr(Y = 1 | X = x)$;
- Uma medida contínua de incerteza associada à decisão;
- Uma saída que pode ser ajustada a diferentes contextos operacionais por meio de um ponto de corte.

A interpretação probabilística emerge da aplicação da função logística ao termo linear $b_0 + b_1x_1 + \dots + b_kx_k$. Esse valor linear, isoladamente, não possui significado probabilístico: ele representa apenas o *log-odds* do evento. A função logística transforma esse valor em uma probabilidade válida, de modo que $p(x) = Pr(Y = 1 |$

$X = x$) pode ser interpretado como a chance estimada de que a observação x pertença à classe positiva.

Essa interpretação é particularmente relevante em ambientes corporativos e industriais, nos quais decisões raramente são binárias por natureza. Em diversas situações, é mais relevante estimar a probabilidade de um cliente cancelar um serviço, de um equipamento falhar ou de uma transação ser fraudulenta, do que apenas classificar a observação como “sim” ou “não”.

Além disso, a probabilidade estimada pelo modelo permite incorporar a incerteza no processo decisório, ajustar diferentes limiares conforme o custo dos erros, priorizar ações (como priorizar clientes com maior risco de *churn*/cancelamento) e avaliar impacto operacional, especialmente em classificação desbalanceada.

Em síntese, a função logística transforma um modelo linear em um mecanismo probabilístico capaz de quantificar incertezas, expressar risco e fornecer uma base sólida para decisões classificatórias informadas.

2.3 A função de custo: Entropia cruzada

O ajuste dos parâmetros na regressão logística não pode ser feito usando o erro quadrático médio, pois essa escolha gera uma função de custo não convexa e conduz a problemas de otimização. Em vez disso, utiliza-se uma função de custo derivada diretamente do modelo probabilístico: a função negativa de log-verossimilhança, que, no contexto binário, é equivalente à entropia cruzada.

Considerando uma amostra de n observações independentes, a função de custo da regressão logística é dada por:

$$J(b) = - \sum_{i=1}^n [y_i \ln(p(x_i)) + (1 - y_i) \ln(1 - p(x_i))]]$$

Essa expressão resulta da suposição de que a variável resposta Y segue uma distribuição Bernoulli condicionada às variáveis preditoras X . Assim, a verossimilhança do modelo é maximizada quando as probabilidades previstas $p(x_i)$ se aproximam das respostas observadas y_i . Tomando o logaritmo e mudando o sinal, obtém-se a função negativa de log-verossimilhança, usada como critério de minimização.

A entropia cruzada possui três características essenciais:

- Penaliza erros de maneira assimétrica e mais severa quando o modelo erra com grande confiança. Por exemplo: prever $p(x_i) = 0,99$ quando o rótulo verdadeiro é $y_i = 0$ resulta em custo altíssimo;
- Leva a uma função de custo convexa em relação aos parâmetros, o que garante convergência dos métodos de otimização baseados em gradiente;
- Estabelece correspondência direta com o modelo probabilístico, alinhando o processo de treinamento com o objetivo de estimar adequadamente a probabilidade condicional $Pr(Y = 1 | X = x)$.

Essa função também favorece modelos que produzem probabilidades bem calibradas, característica relevante em aplicações que exigem quantificação de risco e tomada de decisão baseada em probabilidades, como detecção de fraude, previsão de cancelamento e classificação médica.

Por esses motivos, a entropia cruzada é o critério padrão para ajuste da regressão logística e constitui um dos fundamentos teóricos mais importantes para algoritmos de classificação amplamente utilizados na prática.

2.4 Otimização via gradiente descendente

O processo de ajuste da regressão logística consiste em encontrar os valores dos coeficientes que minimizam a função de custo, isto é, os parâmetros que melhor explicam os dados observados. Para realizar esse ajuste, utiliza-se o gradiente descendente, um método iterativo de otimização muito empregado em *machine learning*. O seu objetivo central é identificar a direção em que a função de custo diminui mais rapidamente e mover os coeficientes nessa direção a cada iteração.

Em termos funcionais, o gradiente atua como um indicador de inclinação: ele mede o quanto a função de custo varia em relação a cada coeficiente. Valores positivos ou negativos informam se o parâmetro deve ser aumentado ou reduzido para aproximar o modelo de uma solução melhor. Assim, a regra de atualização segue o princípio de deslocar cada coeficiente no sentido contrário ao gradiente, reduzindo progressivamente o valor da função de custo. Na forma simplificada, cada coeficiente é atualizado conforme:

$$b_j \leftarrow b_j - \alpha \left(\frac{\partial J}{\partial b_j} \right).$$

Nesse contexto, o termo α representa a taxa de aprendizado e controla o tamanho dos passos dados pelo algoritmo. Passos muito grandes podem fazer o processo divergir, enquanto passos muito pequenos tornam o ajuste lento.

Esse mecanismo é eficiente, fundamentado matematicamente e constitui a base conceitual de métodos mais avançados utilizados em redes neurais e em modelos modernos de aprendizado de máquina. A essência do método é simples: o gradiente descendente orienta o modelo a reduzir seus erros a cada iteração, ajustando os coeficientes até alcançar valores que representem a melhor aproximação das probabilidades observadas nos dados.

3 IMPLEMENTAÇÃO COMPUTACIONAL

A implementação computacional da regressão logística permite transformar a formulação matemática do modelo em um procedimento operacional capaz de lidar com dados reais. Aqui, vamos apresentar como o algoritmo é aplicado em ambientes de programação, destacando o uso da biblioteca *scikit-learn*, que fornece uma interface padronizada para ajuste, predição e análise de modelos de classificação.

3.1 Estrutura geral no *scikit-learn*

A biblioteca *scikit-learn* oferece uma implementação consolidada da regressão logística, permitindo que o modelo seja aplicado de forma simples e padronizada. O processo segue uma lógica clara: primeiro cria-se o objeto do modelo, depois ele é treinado com os dados disponíveis e finalmente são realizadas as previsões. No código abaixo, observa-se essa sequência essencial. O método `fit` ajusta os coeficientes da regressão logística aos dados de treinamento, o método `predict` retorna a classe estimada para cada observação e o método `predict_proba` fornece as probabilidades associadas a cada classe, que são fundamentais para interpretar o modelo de maneira probabilística.

```
from sklearn.linear_model import LogisticRegression
```

```
model = LogisticRegression()  
model.fit(X_train, y_train)  
model.predict(X_test)  
model.predict_proba(X_test)
```

Código-fonte 1 – Estrutura básica de uso da regressão logística no *scikit-learn*
Fonte: Elaborado pela autora (2025)

É importante que a análise siga a seguinte lógica: as probabilidades devem ser sempre observadas primeiro, pois elas representam a saída principal do modelo; somente depois aplica-se um ponto de corte para realizar a classificação. Esse procedimento garante decisões mais transparentes, ajustáveis e adequadas às necessidades de cada contexto.

3.2 Exemplo com dados sintéticos

Em muitos cenários reais de classificação binária, nem sempre temos uma base de dados disponível durante o processo de aprendizagem. Por isso, vamos utilizar dados sintéticos para simular situações reais, testar modelos, estudar seu comportamento e compreender como a regressão logística aprende padrões a partir das variáveis explicativas.

Imagine que uma empresa deseja prever quais clientes têm maior probabilidade de cancelar o serviço nos próximos meses. Para isso, são avaliadas três características básicas do comportamento de uso: o tempo total de utilização do serviço, o nível de engajamento nas últimas semanas e a frequência de acesso à plataforma. A partir desses dados, o modelo de regressão logística estima a probabilidade de cancelamento, permitindo que a instituição identifique clientes em risco e adote ações de retenção de forma antecipada. Nesse exemplo, a variável y é equivalente a 1, ou seja, o cliente cancela o serviço. Já a variável y igual a 0 corresponde ao cliente que permanece.

O exemplo a seguir cria artificialmente um conjunto de dados com três características e uma variável resposta binária que depende delas, permitindo replicação fácil em qualquer contexto.

```
import numpy as np  
from sklearn.linear_model import LogisticRegression  
from sklearn.model_selection import train_test_split
```

```
np.random.seed(42)

# Base com 200 observações e 2 variáveis
X = np.random.rand(200, 2)

# Variável resposta binária simulando risco de cancelamento
y = (0.8 * X[:, 0] - 0.4 * X[:, 1] > 0.2).astype(int)

# Divisão treino (70%) e teste (30%)
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.3)

# Ajuste do modelo
model = LogisticRegression()
model.fit(X_train, y_train)

# Exibição das probabilidades previstas
print("Probabilidades:",
model.predict_proba(X_test[:5]))
```

Código-fonte 2 – Modelo de regressão logística aplicado a dados artificiais

Fonte: Elaborado pelo autor (2019)

O código apresentado constrói um conjunto de dados artificiais e ajusta um modelo de regressão logística utilizando a biblioteca *scikit-learn*. Primeiro, são geradas 200 observações com três variáveis independentes, cada uma contendo valores aleatórios entre 0 e 1. Em seguida, define-se um critério para construir a variável resposta binária: combina-se linearmente as três variáveis e transforma-se esse resultado em um valor 0 ou 1, simulando uma decisão binária como “risco baixo” ou “risco alto”. Depois, os dados são divididos em uma parte para treinamento e outra para teste.

O modelo `LogisticRegression` é então ajustado com os dados de treinamento, aprendendo a relação entre as características e o desfecho binário. Por fim, o código imprime as probabilidades previstas para algumas observações de teste, ilustrando como o modelo estima a chance de ocorrência do evento de interesse.

Na figura a seguir podemos observar o resultado desse código.

```
Probabilidades: [[0.89441567 0.10558433]
 [0.90182195 0.09817805]
 [0.05466875 0.94533125]
 [0.30746581 0.69253419]
 [0.20364759 0.79635241]]
```

Figura 2 – Print do resultado código-fonte 2
Fonte: Elaborada pela autora (2025)

O comando `model.predict_proba(X_test[:5])` retorna, para cada uma das primeiras 5 observações do conjunto de teste, as probabilidades previstas pelo modelo para cada classe.

Cada linha representa a probabilidade prevista pelo modelo de que a observação pertencerá à classe 0 (de não cancelar) ou à classe 1 (de cancelar). A soma das duas probabilidades é sempre igual a 1. O modelo estima essas probabilidades com base nas características de cada cliente. Desse modo, quando a probabilidade da classe 1 é superior a 0,5, o modelo classifica o cliente como propenso ao cancelamento. Quando é inferior, classifica como permanência.

Esse exemplo possibilita a compreensão da lógica fundamental do processo de treinamento, predição e interpretação da regressão logística, podendo facilmente adaptar o código para diversos contextos reais.

3.3 Fronteira de decisão

Quando trabalhamos com regressão logística aplicada a apenas duas variáveis explicativas, é possível visualizar de forma clara a linha que separa as duas classes. Essa separação é chamada de fronteira de decisão. Ela corresponde ao conjunto de pontos em que o modelo atribui probabilidade igual a 0,5 para a classe positiva. Em termos matemáticos, essa fronteira ocorre quando a combinação linear dos preditores é igual a zero, ou seja, quando $b_0 + b_1x_1 + b_2x_2 = 0$.

Essa linha desempenha um papel fundamental na classificação: ela divide o espaço das variáveis em duas regiões distintas. Essa linha pode ser escrita como `decision_boundary = -(b0 + b1 * x_values) / b2` no código.

De um lado, encontram-se os pontos para os quais o modelo estima $Pr(Y = 1 | X)$ maior que 0,5, sendo então classificados como pertencentes à classe positiva.

Do outro lado, ficam os pontos cuja probabilidade é inferior a 0,5, classificados como pertencentes à classe negativa. A linha de decisão pode ser vista na figura abaixo.




Figura 3 – Representação da fronteira de decisão
Fonte: Elaborada pela autora (2025)

Essa linha separa o plano formado pelas duas variáveis explicativas (X_1 e X_2) em duas regiões distintas. Em cada ponto do plano, o modelo calcula a probabilidade da observação pertencer à classe positiva. Quando essa probabilidade é igual a 0,5, o modelo se encontra exatamente sobre a linha, por isso a fronteira corresponde a essa condição.

Os pontos azuis indicam exemplos que pertencem à classe 0, ou seja, clientes que permanecem no serviço, enquanto os pontos vermelhos representam a classe 1, que são os clientes que cancelam. O modelo ajusta a linha de forma a posicionar, de um lado dela, a maioria dos pontos de uma classe e, do outro lado, a maioria da classe oposta.

Assim, tudo que está acima da linha é interpretado como mais provável de pertencer à classe azul, porque nessas regiões do plano a combinação linear dos coeficientes tende a gerar valores negativos e, portanto, probabilidades menores do que 0,5. Por outro lado, os pontos abaixo da linha são considerados mais prováveis de pertencer à classe vermelha, pois a combinação linear tende a produzir valores positivos, gerando probabilidades acima de 0,5.

Em resumo, a fronteira de decisão mostra como o modelo transforma as duas variáveis preditoras em decisões classificatórias: ela marca exatamente onde o

modelo fica “indiferente” entre as duas classes e divide o espaço em regiões em que uma classe é mais provável que a outra.

3.4 Interpretação dos coeficientes

Os coeficientes da regressão logística possuem uma interpretação direta e bastante útil em aplicações reais. Cada coeficiente indica como a chance (*odds*) do evento ocorrer muda quando a variável explicativa correspondente aumenta em uma unidade, mantendo todas as demais constantes. Ao aplicar a função exponencial ao coeficiente b_j , obtém-se o fator multiplicativo que atua sobre as chances: $\exp(b_j)$ mostra exatamente por quanto as chances são multiplicadas quando x_j aumenta em uma unidade.

Considere dois exemplos:

- Se $\exp(b_1) = 1,5$, isso significa que, ao aumentar x_1 em uma unidade, as chances do evento ocorrer aumentam em 50%. Em termos práticos, a variável x_1 exerce um efeito positivo sobre o risco: quanto maior seu valor, maior a probabilidade do evento (como cancelamento ou falha);
- Se $\exp(b_2) = 0,7$, isso indica que, ao aumentar x_2 em uma unidade, as chances do evento reduzem para 70% do valor anterior, no caso a chance reduz em 30%. Aqui, x_2 atua como fator protetivo: quanto maior o seu valor, menor a probabilidade do evento acontecer.

Essa interpretação é especialmente valiosa em contextos de negócios e decisões operacionais, pois permite identificar quais variáveis aumentam ou reduzem significativamente o risco de um evento acontecer. Um coeficiente positivo indica que o aumento da variável eleva as chances do evento ocorrer, como maior probabilidade de cancelamento, falha ou fraude. Já um coeficiente negativo indica que o aumento da variável reduz essas chances. Dessa forma, a análise dos coeficientes permite compreender o efeito marginal de cada variável no modelo e auxilia na tomada de decisões mais informadas.

4 AVALIAÇÃO DO MODELO

A etapa de avaliação é fundamental para verificar se o modelo de regressão logística está realmente capturando o padrão dos dados e se tem capacidade de tomar boas decisões em novos cenários. Cada métrica oferece uma perspectiva específica sobre o desempenho do modelo, e a escolha adequada deve considerar o contexto e o tipo de risco envolvido.

4.1 Métricas fundamentais

Os indicadores clássicos utilizados na avaliação de classificadores binários ajudam a medir diferentes aspectos do desempenho. Métricas como acurácia, precisão, *recall*, sensibilidade, especificidade e *F1-score* destacam-se.

A acurácia mede a proporção total de acertos, enquanto a precisão e o *recall* permitem avaliar separadamente o comportamento do modelo em relação aos verdadeiros positivos. A sensibilidade (equivalente ao *recall* da classe positiva) indica a capacidade de identificar corretamente os casos em que o evento ocorre, enquanto a especificidade mede a capacidade de identificar corretamente os casos em que o evento não ocorre. O *F1-score* combina precisão e *recall* em uma única medida, sendo especialmente útil quando existe algum grau de desbalanceamento entre as classes.

Essas métricas são adequadas para situações em que o conjunto de dados é balanceado ou apenas moderadamente desbalanceado, pois oferecem uma visão equilibrada do desempenho do modelo em diferentes dimensões.

4.2 Curva ROC e AUC

A curva ROC (*Receiver Operating Characteristic*) é uma ferramenta poderosa para avaliar o desempenho de classificadores probabilísticos. Ela mostra como o modelo se comporta ao variar o limiar de decisão que transforma probabilidades em classes. Essa curva revela o compromisso entre taxa de verdadeiros positivos e taxa de falsos positivos ao longo de diferentes limiares.

O AUC (*Area Under the Curve*) resume essa análise em um único valor, indicando a capacidade média do modelo de distinguir corretamente entre as duas

classes. Valores próximos de 1 indicam excelente desempenho, enquanto valores próximos de 0,5 correspondem a um modelo que não discrimina melhor do que o acaso.

4.3 Validação cruzada

Além de avaliar métricas pontuais, é essencial garantir que o desempenho do modelo não dependa de uma única divisão entre treino e teste. Uma modelagem confiável exige métodos que estimem de forma robusta a capacidade de generalização. A validação cruzada cumpre esse papel ao treinar e testar o modelo em várias partições diferentes da base de dados, permitindo avaliar sua estabilidade e reduzir a influência do acaso.

Esse procedimento fornece uma estimativa mais realista do desempenho esperado em novos dados e é amplamente utilizado em *pipelines* modernos de aprendizado de máquina.

4.4 Exemplo

Vamos usar o exemplo de uma empresa que deseja prever quais clientes têm maior probabilidade de cancelar o serviço nos próximos meses, considerando a mesma base do código apresentada a seguir.

```
from sklearn.metrics import accuracy_score,
precision_score, recall_score, f1_score, confusion_matrix

# Previsões das classes
y_pred = model.predict(X_test)

# Métricas fundamentais
print("Acurácia:", accuracy_score(y_test, y_pred))
print("Precisão:", precision_score(y_test, y_pred))
print("Recall (Sensibilidade):", recall_score(y_test,
y_pred))
print("F1-score:", f1_score(y_test, y_pred))

# Matriz de confusão
print("Matriz de confusão:\n", confusion_matrix(y_test,
y_pred))
```

Código-fonte 3 – Exemplo de código-fonte HTML
Fonte: Elaborado pela autora (2025)

As métricas fundamentais apresentam como resultado os dados obtidos na figura abaixo.

```
Acurácia: 0.95  
Precisão: 0.9117647058823529  
Recall (Sensibilidade): 1.0  
F1-score: 0.9538461538461539
```

Figura 4 – Métricas fundamentais do modelo
Fonte: Elaborada pela autora (2025)

Os resultados mostram que o modelo acerta 95% das previsões (acurácia), identifica corretamente todos os casos positivos (*recall* igual a 1,0) e comete poucos falsos positivos (precisão de 0,91). O *F1-score* de 0,95 evidencia o equilíbrio entre precisão e *recall*, indicando que o modelo apresenta excelente desempenho geral. Em um cenário de cancelamento, por exemplo, isso significa que o modelo identifica todos os clientes em risco sem gerar um número excessivo de alarmes falsos.

Já a matriz de confusão apresenta o resultado visto abaixo.

```
Matriz de confusão:  
[[26  3]  
 [ 0 31]]
```

Figura 5 – Matriz de confusão do modelo
Fonte: Elaborada pela autora (2025)

Essa matriz de confusão mostra que o modelo classifica muito bem os dois grupos: ele acertou 26 dos 29 clientes que realmente não iriam cancelar, errando apenas 3 previsões nessa classe. Por outro lado, identificou corretamente todos os 31 clientes que iriam cancelar, sem cometer falsos negativos. Isso indica que o modelo tem excelente capacidade de detecção da classe positiva, sendo útil para situações em que é crítico identificar clientes em risco de cancelamento.

A matriz de confusão reforça os resultados das métricas fundamentais: o modelo apresenta elevada acurácia e *recall* perfeito, com poucos falsos positivos e nenhum falso negativo. Isso significa que, além de acertar a maior parte das previsões, o modelo é competente em identificar corretamente os casos da classe positiva, característica fundamental em contextos em que a omissão de casos críticos representa alto custo.

5 APLICAÇÕES E CONEXÕES DA REGRESSÃO LOGÍSTICA

A regressão logística é um dos modelos mais utilizados em ciência de dados aplicada, devido à sua simplicidade, velocidade de treinamento, robustez estatística e facilidade de interpretação. Por ser um modelo linear probabilístico, ela permite estimar a chance de um evento ocorrer, o que a torna apropriada para problemas de classificação binária em diferentes áreas organizacionais. Em marketing digital, por exemplo, ela é empregada para estimar a probabilidade de um usuário clicar em um anúncio ou realizar uma conversão. Na indústria, aparece em cenários de detecção de falhas e manutenção preditiva, permitindo identificar padrões de funcionamento que antecedem quebras. No setor financeiro, é usada para estimar o risco de inadimplência, já em TI e cibersegurança, auxilia na identificação de acessos anômalos e, em sistemas de recomendação, apoia a previsão de aceitação de sugestões.

A regressão logística é frequentemente adotada como modelo *baseline* em *pipelines* de aprendizado de máquina, justamente por produzir probabilidades bem calibradas e servir como referência para modelos mais sofisticados. Além disso, ela ocupa uma posição conceitual estratégica dentro do ecossistema de modelos de classificação. Homem (2020) destaca que o neurônio de saída de uma rede neural multicamadas nada mais é do que uma regressão logística aplicada a uma combinação não linear de atributos, o que faz desse modelo um elo natural entre a estatística clássica e modelos de *deep learning*. De forma complementar, Izbicki & Santos relacionam a regressão logística à análise discriminante linear, aos classificadores bayesianos e às abordagens generativas, reforçando como ela se conecta a diferentes tradições metodológicas dentro da classificação. Assim, ela cumpre um papel fundamental: ao mesmo tempo em que resolve problemas reais de maneira eficaz, fornece a base conceitual para tecnologias mais avançadas em *machine learning*.

5.1 Exemplo de detecção de acesso suspeito

Considere uma equipe de segurança da informação que deseja identificar acessos potencialmente suspeitos em um sistema corporativo. Cada tentativa de login é descrita por três variáveis:

- X_1 : horário do acesso (valores próximos de 1 indicam horários mais atípicos, como madrugada);
- X_2 : distância geográfica em relação ao último acesso do usuário (normalizada entre 0 e 1);
- X_3 : proporção recente de falhas de login para o mesmo usuário (também entre 0 e 1).

A variável resposta Y indica se o acesso foi considerado suspeito (1) ou normal (0), com base em análises anteriores da equipe. Para fins exclusivamente didáticos, utilizaremos apenas 20 observações, apresentadas a seguir. Em um projeto real de aprendizado de máquina, o ideal seria trabalhar com todo o histórico disponível de acessos para obter estimativas mais robustas.

Linha	X_1 (horário)	X_2 (distância)	X_3 (falhas recentes)
1	0.15	0.10	0.00
2	0.20	0.15	0.10
3	0.30	0.40	0.10
4	0.25	0.20	0.30
5	0.40	0.35	0.20
6	0.45	0.50	0.10
7	0.60	0.55	0.20
8	0.65	0.60	0.40
9	0.70	0.65	0.50
10	0.75	0.70	0.60
11	0.80	0.80	0.70
12	0.90	0.85	0.80
13	0.95	0.90	0.90
14	0.50	0.80	0.70
15	0.30	0.90	0.80
16	0.85	0.40	0.20
17	0.10	0.70	0.60
18	0.55	0.30	0.80
19	0.35	0.60	0.30
20	0.65	0.20	0.70

Tabela 1 – Tentativas de acesso simuladas
Fonte: Elaborada pela autora (2025)

A partir desses dados, o modelo de regressão logística será ajustado para estimar a probabilidade de um novo acesso suspeito, dadas as três características X_1 , X_2 e X_3 .

```
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score,
precision_score, recall_score, f1_score, confusion_matrix

# Dados: 20 observações, 3 variáveis explicativas
X = np.array([
    [0.15, 0.10, 0.00],
    [0.20, 0.15, 0.10],
    [0.30, 0.40, 0.10],
    [0.25, 0.20, 0.30],
    [0.40, 0.35, 0.20],
    [0.45, 0.50, 0.10],
    [0.60, 0.55, 0.20],
    [0.65, 0.60, 0.40],
    [0.70, 0.65, 0.50],
    [0.75, 0.70, 0.60],
    [0.80, 0.80, 0.70],
    [0.90, 0.85, 0.80],
    [0.95, 0.90, 0.90],
    [0.50, 0.80, 0.70],
    [0.30, 0.90, 0.80],
    [0.85, 0.40, 0.20],
    [0.10, 0.70, 0.60],
    [0.55, 0.30, 0.80],
    [0.35, 0.60, 0.30],
    [0.65, 0.20, 0.70],
])

y = np.array([
    0, 0, 0, 0, 0, 0, 0, 0, # linhas 1 a 7
    1, 1, 1, 1, 1, 1,      # linhas 8 a 13
    1, 1,                  # linhas 14 e 15
    0,                     # linha 16
    1, 1,                  # linhas 17 e 18
    0,                     # linha 19
    1                       # linha 20
])

# Divisão treino (70%) e teste (30%)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42
)

# Ajuste do modelo de regressão logística
```



```
model = LogisticRegression()
model.fit(X_train, y_train)

# Probabilidades previstas para alguns acessos de teste
print("Probabilidades previstas:",
model.predict_proba(X_test))

# Previsões de classe
y_pred = model.predict(X_test)

print("Acurácia:", accuracy_score(y_test, y_pred))
print("Precisão:", precision_score(y_test, y_pred))
print("Recall (Sensibilidade):", recall_score(y_test,
y_pred))
print("F1-score:", f1_score(y_test, y_pred))
print("Matriz de confusão:\n", confusion_matrix(y_test,
y_pred))
```

Código-fonte 4 – Regressão logística com três variáveis e 20 observações
Fonte: Elaborada pela autora (2025)

A figura apresenta o resultado do código-fonte “Regressão logística com três variáveis e 20 observações”.

```
Probabilidades previstas: [[0.62606078 0.37393922]
 [0.32272173 0.67727827]
 [0.43088902 0.56911098]
 [0.58459182 0.41540818]
 [0.3297728 0.6702272 ]
 [0.49461347 0.50538653]]
Acurácia: 0.6666666666666666
Precisão: 0.5
Recall (Sensibilidade): 1.0
F1-score: 0.6666666666666666
Matriz de confusão:
[[2 2]
 [0 2]]
```

Figura 6 – Impressão do código-fonte 4
Fonte: Elaborada pela autora (2025)

Os resultados obtidos com a regressão logística do problema apresentado possuem acurácia de aproximadamente 66,7%, o que indica que o modelo acertou dois terços das classificações realizadas, sendo compatível com o tamanho pequeno da amostra utilizada. A precisão de 0,5 mostra que apenas metade das previsões marcadas como “acesso suspeito” eram realmente corretas, revelando a presença de falsos positivos.

Em contrapartida, o *recall* igual a 1,0 demonstra que o modelo identificou corretamente todos os acessos que eram de fato suspeitos, sem deixar passar nenhum caso crítico, característica particularmente relevante em cenários de cibersegurança. O *F1-score* atingiu cerca de 0,67, refletindo um desempenho intermediário. Esses comportamentos ficam evidentes na matriz de confusão: o modelo classificou corretamente dois acessos normais e dois suspeitos, mas gerou duas classificações incorretas ao marcar acessos legítimos como suspeitos. Em síntese, o modelo tende a ser conservador, preferindo sinalizar possíveis riscos mesmo que isso gere alguns alarmes falsos, ao mesmo tempo em que mantém alta sensibilidade para detectar acessos potencialmente perigosos.

Para interpretar os coeficientes, podemos aplicar o seguinte código:

```
import numpy as np

coef = model.coef_[0]
intercepto = model.intercept_[0]

print("Intercepto:", intercepto)
print("Coeficientes:", coef)
print("exp(b_j):", np.exp(coef))
```

Código-fonte 5 – Código para encontrar os coeficientes

Fonte: Elaborada pela autora (2025)

O código fonte “Código para encontrar os coeficientes” tem como saída o resultado demonstrado abaixo.

```
Intercepto: -0.6601404067713574
Coeficientes: [0.52200921 0.66484826 1.14359079]
exp(b_j): [1.68541059 1.94419549 3.13801612]
```

Figura 7 – Impressão do código-fonte 5

Fonte: Elaborada pela autora (2025)

O intercepto estimado pelo modelo, cerca de $-0,66$, representa o *log-odds* de um acesso ser suspeito quando todas as variáveis têm valor zero. Já os coeficientes positivos das três variáveis indicam que, à medida que cada uma delas aumenta, também aumentam as chances de o acesso ser classificado como suspeito. Para facilitar a interpretação, utilizamos $\exp(b_j)$: valores de aproximadamente 1,68, 1,94 e 3,14 mostram que um aumento unitário em X_1 , X_2 e X_3 multiplica as chances de suspeita em cerca de 68%, 94% e mais de três vezes, respectivamente. Isso evidencia

que todas as variáveis contribuem para elevar o risco previsto pelo modelo, sendo X_3 a de maior impacto.

Para encontrar a fronteira de decisão, podemos utilizar o código a seguir.

```
import numpy as np
import matplotlib.pyplot as plt

# Coeficientes do modelo treinado com 3 variáveis
b0 = model.intercept_[0]
b1, b2, b3 = model.coef_[0]

# Fixando X3 como a média dos valores observados
x3_const = X[:, 2].mean()

# Grid de X1 para desenhar a linha
x_values = np.linspace(0, 1, 100)

# Fronteira de decisão projetada em (X1, X2) com X3 fixo
decision_boundary = -(b0 + b1 * x_values + b3 * x3_const)
/ b2

# Plot dos dados reais (X1, X2)
plt.scatter(X[:, 0], X[:, 1], c=y, cmap="coolwarm",
edgecolor="k")

# Plot da linha de fronteira de decisão
plt.plot(x_values, decision_boundary, color="black",
linewidth=2)

plt.xlabel("X1 (horário)")
plt.ylabel("X2 (distância)")
plt.title("Fronteira de decisão projetada (X3 fixo na
média)")
plt.ylim(0, 1)
plt.xlim(0, 1)
plt.show()
```

Código-fonte 6 – Código da fronteira de decisão com variável fixa
Fonte: Elaborado pela autora (2025)

Para visualizar a fronteira de decisão de um modelo com três variáveis em um plano bidimensional, é necessário “congelar” uma das variáveis em um valor constante. No exemplo, optamos por fixar X_3 em sua média, pois esse é um valor neutro, representativo do comportamento geral da variável ao longo da base de dados. Fixar X_3 na média reduz distorções e evita que a projeção favoreça cenários extremos, permitindo observar como X_1 e X_2 influenciam a probabilidade prevista, enquanto X_3

permanece em um nível típico. Essa abordagem produz uma visualização mais estável, interpretável e coerente com o conjunto de dados.

O código “Código da fronteira de decisão com variável fixa” tem como saída o resultado apresentado a seguir.




Figura 8 – Impressão do código-fonte 6

Fonte: Elaborada pela autora (2025)

A figura apresenta a fronteira de decisão projetada do modelo de regressão logística no plano formado pelas variáveis X_1 (horário) e X_2 (distância). Como o modelo utiliza três variáveis explicativas, a fronteira real está definida em um espaço tridimensional. Para possibilitar a visualização, fixamos a terceira variável (X_3) em seu valor médio e representamos apenas o efeito conjunto de X_1 e X_2 . A linha preta indica o conjunto de pontos em que o modelo estima probabilidade igual a 0,5 para a classe positiva, no caso de acesso suspeito. Dessa forma, os pontos acima da linha tendem a ser classificados como acessos normais, apresentados em azul, enquanto os pontos abaixo da linha são mais propensos a serem classificados como suspeitos, que estão em vermelho no gráfico. Essa projeção permite observar como o modelo separa as duas classes de forma linear quando X_3 é mantido constante, ilustrando de maneira intuitiva o funcionamento da regressão logística em problemas com múltiplas variáveis.

Esse mesmo exemplo, sendo feito com a base de dados original, que contém 643 dados, apresenta os resultados dispostos na figura:

```

Probabilidades previstas: [[3.04243578e-01 6.95756422e-01]
 [6.96480036e-04 9.99303520e-01]
 [9.48378865e-03 9.90516211e-01]
 [4.14370968e-01 5.85629032e-01]
 [9.03960068e-02 9.09603993e-01]]
Acurácia: 0.9844559585492227
Precisão: 0.9767441860465116
Recall (Sensibilidade): 1.0
F1-score: 0.9882352941176471
Matriz de confusão:
[[ 64   3]
 [  0 126]]

Intercepto: -6.460468057960809
Coeficientes: [3.99977012 4.45316989 6.37821802]
exp(b_j): [ 54.58560069  85.89880227 588.8774023 ]

```

Figura 9 – Impressão do código-fonte para 643 dados

Fonte: Elaborada pela autora (2025)

As probabilidades previstas representam a saída probabilística da regressão logística para algumas observações do conjunto de teste. Cada linha apresenta dois valores: a probabilidade da observação ser classificada como normal (classe 0) e a probabilidade de ser classificada como suspeita (classe 1). Essas estimativas mostram como o modelo quantifica o risco antes de aplicar qualquer ponto de corte. Em seguida, as métricas de avaliação revelam o desempenho global: a acurácia de aproximadamente 98,4% indica que o modelo acerta quase todas as previsões, a precisão de 97,6% mostra que, entre os acessos classificados como suspeitos, a grande maioria realmente pertencia à classe positiva, o *recall* igual a 1,0 evidencia que o modelo identificou todos os acessos suspeitos, sem deixar passar nenhum caso crítico, e o *F1-score* confirma o excelente equilíbrio entre esses dois indicadores. A matriz de confusão reforça esse comportamento: dos 67 acessos verdadeiramente normais, apenas 3 foram classificados incorretamente como suspeitos, enquanto todos os 126 acessos suspeitos foram corretamente detectados.

Por fim, os coeficientes estimados pelo modelo permitem interpretar a contribuição individual de cada variável. O intercepto representa o *log-odds* do evento quando todas as variáveis são zero. Já os coeficientes associados às três variáveis explicativas, cerca de 3,99, 4,45 e 6,37, revelam que todas aumentam significativamente a chance de um acesso ser suspeito. A interpretação fica ainda mais intuitiva com $\exp(b_j)$: os valores aproximados de 54,6, 85,9 e 588,9 indicam que, a cada unidade adicional em cada variável, as chances de suspeita são multiplicadas

por esses fatores, mostrando que a terceira variável exerce o impacto mais intenso. Esses resultados evidenciam um modelo altamente sensível, preciso e alinhado com o comportamento esperado dos dados simulados.

6 CONCLUSÃO

Em síntese, o estudo da regressão logística permitiu integrar fundamentos estatísticos, formulação matemática, implementação computacional e interpretação aplicada dos resultados. A análise das probabilidades previstas, das métricas de desempenho, da matriz de confusão e dos coeficientes do modelo mostrou como esse método, apesar de simples, é extremamente poderoso para problemas de classificação binária. Além de fornecer previsões probabilísticas claras, o modelo mantém elevada interpretabilidade e forte coerência teórica, tornando-se uma ferramenta fundamental para tomada de decisão em diferentes contextos. Os exemplos desenvolvidos, tanto com bases pequenas quanto com um conjunto maior de dados, reforçam a importância de compreender não apenas a operação do algoritmo, mas também suas implicações práticas e sua capacidade de generalização. Assim, a regressão logística se consolida não apenas como um ponto de partida para modelos mais avançados, mas como um componente essencial em *pipelines* de análise e aprendizado de máquina modernos.

REFERÊNCIAS

- BISHOP, Christopher M. **Pattern Recognition and Machine Learning**. New York: Springer, 2006.
- BLUM, Avrim; HOPCROFT, John; KANNAN, Ravindran. **Foundations of Data Science**. 2020.
- FARIAS, Ana Maria Lima de. **Probabilidade e Estatística**. 2. ed. São Paulo: Pearson, 2017.
- GOES, Geraldo; YWATA, Alexandre. **Introdução à Regressão Logística**. 2019.
- HOMEM, Pedro Lucas. **Machine Learning – Uma abordagem estatística e computacional**. São Paulo: 2020.
- IZBICKI, Rafael; SANTOS, Tiago Mendonça dos. **Aprendizagem de Máquina – Uma abordagem estatística**. 1. ed. Rio de Janeiro: LTC, 2020.
- SIMEONE, Osvaldo. **A Brief Introduction to Machine Learning for Engineers**. Foundations and Trends in Signal Processing, v. 12, n. 3–4, p. 200–431, 2018.
- THOMAS, Marc Peter Deisenroth; FAUSETT, A. Aldo; ONG, Cheng Soon. **Mathematics for Machine Learning**. Cambridge: Cambridge University Press, 2018.

GLOSSÁRIO

Acurácia	Proporção total de acertos do modelo, considerando simultaneamente as classes positivas e negativas.
Chances (odds)	Razão entre a probabilidade de um evento ocorrer e a probabilidade de ele não ocorrer. Utilizada na interpretação dos coeficientes logísticos.
Entropia cruzada (Cross-Entropy)	Função de custo utilizada na regressão logística. Mede a discrepância entre as probabilidades previstas pelo modelo e as classes reais.
F1-score	Métrica que combina precisão e <i>recall</i> em um único número, útil em casos de desbalanceamento moderado entre as classes.
Log-odds (Logito)	Transformação logarítmica das chances. Permite modelar probabilidades com uma função linear.
Máxima verossimilhança	Método estatístico para estimar parâmetros. Na regressão logística, busca os coeficientes que maximizam a probabilidade de observar os dados reais.
Matriz de confusão	Tabela que resume acertos e erros do modelo, classificando exemplos entre positivo e negativo.

Validação cruzada (<i>Cross-validation</i>)	Técnica de avaliação que divide os dados em múltiplas partições, garantindo estimativas mais robustas de desempenho e generalização.
--	--

EXEMPLO